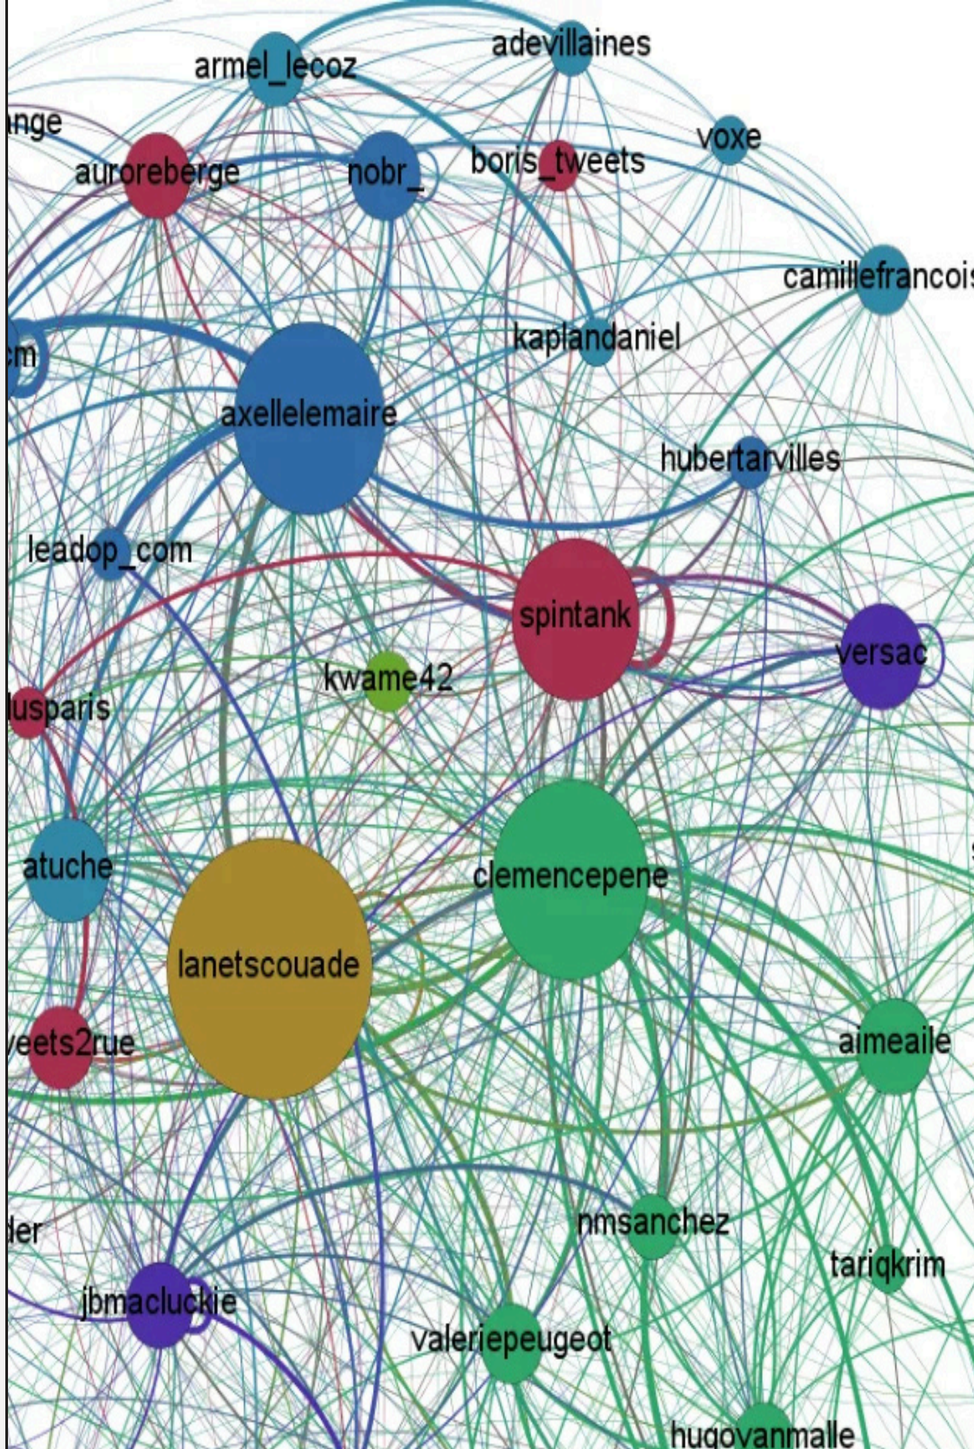
INTRODUCTION AU BIG DATA

Quand les données changent d'échelle

M. FALL Ingénieur IA & Big Data



Facebook reçoit des centaines de milliers de photos chaque minute. Pourquoi une base MySQL classique ne peut-elle pas gérer ça ?

MySQL gère très bien les données d'une boutique, d'une école, d'une PME. Le problème n'est pas l'outil : c'est l'échelle.

Gardez cette question en tête pendant trois heures. On y répond à la fin de la séance.

REPÈRES

Objectifs de la séance

À la fin de ce cours, vous savez :

01 **Définir** le Big Data avec vos propres mots.

02 **Expliquer** les 5 V qui le caractérisent.

03 **Comprendre** pourquoi les systèmes classiques atteignent leurs limites.

04 **Distinguer** scale-up et scale-out.

05 **Citer** des cas d'usage réels, au Sénégal et ailleurs.

Le module en 10 séances

01	**Pourquoi le Big Data** : enjeux et 5 V (aujourd'hui)	06	**Écosystème Hadoop** : Hive, Pig, HBase, Spark
02	**Architecture & HDFS** : stocker un fichier sur mille machines	07	**Hive : SQL sur Hadoop** : interroger le Big Data en SQL
03	**MapReduce : concepts** : le traitement parallèle	08	**Introduction à Spark :** le traitement en mémoire
04	**MapReduce : pratique** : écrire et lancer un job	09	**Projet fil rouge** : un jeu de données de bout en bout
05	**YARN & orchestration** : gérer les ressources du cluster	10	**Restitutions & évaluation** : présentations

Chaque brique prépare la suivante. On construit les fondations avant l'écosystème.

En 2026, l'humanité génère environ 400 à 500 exaoctets (millions de téraoctets) de données chaque jour à l'échelle mondiale.

Près de 90 % de toutes les données existantes dans le monde ont été créées au cours des deux dernières années seulement.

PARTIE 1

D'où vient toute cette donnée ?

Les sources, les ordres de grandeur, et le seuil à partir duquel on parle de Big Data.



Tout produit de la donnée, en permanence

Réseaux sociaux

Posts, photos, vidéos, likes, commentaires.

Mobile & capteurs

Smartphones, GPS, objets connectés (IoT).

Transactions

Paiements mobiles, e-commerce, mobile money.

Web & logs

Clics, recherches, journaux de serveurs.

Multimédia

Streaming audio et vidéo.

Machines

Télécoms, industrie, télémétrie.

Idée clé. Ces sources produisent de la donnée automatiquement, 24 h/24. Ce n'est plus un humain qui saisit ligne par ligne : c'est le changement de fond.

L'échelle a changé

Ko → Mo — Hier : un fichier

Go → To — Aujourd'hui : une base

Po → Eo — Big Data : un cluster

Po = pétaoctet (1 million de Go) · Eo = exaoctet (1 milliard de Go)

D’ici 2035 : Plus de 643 Eo de données par jour.

L'ANALOGIE

Si **1 Go** est une tasse d'eau, alors **1 Po** est une piscine olympique et **1 Eo**, un lac.

Le Big Data commence quand la donnée ne tient plus sur une seule machine.

Définition

Le Big Data désigne des ensembles de données si **volumineux**, si **rapides** ou si **variés** que les outils traditionnels (bases relationnelles, un seul serveur) ne suffisent plus à les stocker et les traiter.

LE PIÈGE

La bonne définition n'est pas « beaucoup de données » mais « des données que les méthodes habituelles ne peuvent plus gérer ». Une PME avec 10 Go bien rangés n'a pas de problème de Big Data ; Google, si.

Les 5 V

Volume

La quantité

L'historique de tous les appels d'un opérateur (Sonatel).

Vélocité

La vitesse

Les transactions Wave qui arrivent en temps réel.

Variété

Les formats

Un post = texte + photo + vidéo : formats mélangés.

Véracité

La fiabilité

Numéros faux, doublons, champs vides dans un fichier clients.

Valeur

Le but

La recommandation ou la décision qu'on en tire.

Repère historique. Dans les années 2000 on parlait de 3 V : Volume, Vélocité, Variété. Véracité et Valeur ont été ajoutés ensuite : des données fausses ou inexploitées ne valent rien.

ATELIER · EN BINÔME

Exercice 1

Appliquer les 5 V à une organisation que vous connaissez.

25 min

Choisissez **une** entreprise ou un service que vous connaissez : Wave, Sonatel, une boutique en ligne, un hôpital, une école…

01 Citez **3 types de données** que cette organisation produit.

02 Pour chacun, indiquez **à quel V** il correspond.

03 En une phrase : **une base MySQL classique suffirait-elle** à tout gérer ? Pourquoi ?

Pourquoi une base classique ne suffit plus

Un seul serveur, une limite

Une base relationnelle vit sur une machine : on finit par atteindre le plafond de disque, de RAM, de CPU.

Le vertical a un mur, et un prix

Une machine 2× plus puissante coûte bien plus que 2×. Et il existe une machine maximale.

Les données non structurées

SQL gère mal images, vidéos, textes libres et logs : le schéma rigide devient un obstacle.

La panne arrête tout

Un seul serveur qui tombe, et le service entier devient indisponible.

Le problème n'est pas MySQL en soi : c'est l'idée de tout mettre sur une seule machine.

LES DEUX STRATÉGIES

Scale-up ou scale-out ?

	Scale-up (vertical)	Scale-out (horizontal)
PRINCIPE	Une machine, toujours plus grosse	Beaucoup de machines ordinaires ensemble
COÛT	Explose	Maîtrisé, matériel standard
LIMITE	Un mur matériel	Presque sans limite
PANNE	Un seul point de défaillance	Tolérant aux pannes, **le choix de Hadoop**

L'analogie. Pour transporter 100 personnes : un bus géant ou 25 taxis ? Si le bus tombe en panne, tout le monde est bloqué ; si un taxi tombe, 96 passagers arrivent quand même. Le Big Data a choisi les taxis, et l'outil qui les orchestre s'appelle Hadoop.

CONCRÈTEMENT

Cas d'usage

Télécoms

Analyser des milliards d'appels pour prévoir pannes et départs clients.

Banque & mobile money

Détecter une fraude en temps réel sur des millions de transactions.

E-commerce

Recommander le bon produit selon le comportement du client.

Santé

Croiser dossiers et capteurs pour anticiper des épidémies.

Agriculture

Croiser météo, sols et images satellites pour optimiser les rendements.

Transport

Optimiser trajets et logistique à partir des données GPS.

SYNTHÈSE · RETOUR À LA QUESTION

Pourquoi MySQL ne peut-il pas gérer les photos de Facebook ?

Volume

Dépasse ce qu'un seul serveur peut stocker.

Vélocité

Des milliers d'ajouts par seconde saturent une base unique.

Variété

Les images binaires s'accordent mal au schéma relationnel.

La solution

Le scale-out : répartir sur des milliers de machines. C'est Hadoop, séance 2.

LES TROIS IDÉES À EMPORTER

À retenir

01 Big Data = quand les outils classiques ne suffisent plus, pas juste « beaucoup ».

02 On le caractérise par les 5 V : Volume, Vélocité, Variété, Véracité, Valeur.

03 La réponse technique est le scale-out : de nombreuses machines ordinaires qui coopèrent.

LA QUESTION QUI NOUS ATTEND

Comment mille machines stockent-elles un seul fichier ? → **HDFS**

ÉVALUATION · PARTIE A · INDIVIDUEL

30 min au total · noté sur 10

Vrai ou faux, justifié en une ligne

01 « Big Data veut simplement dire beaucoup de données. »

02 « La Vélocité désigne la vitesse à laquelle les données arrivent et doivent être traitées. »

03 « Le scale-up, rendre une machine plus grosse, est la solution retenue par le Big Data. »

04 « Des données fausses ou en double relèvent de la Véracité. »

05 « Une vidéo, un texte et un capteur mélangés, c'est un exemple de Variété. »

ÉVALUATION · PARTIE B · MINI-CAS

Une plateforme de streaming musical

Une plateforme sénégalaise compte des millions d'écoutes par jour, stocke des fichiers audio, des playlists et l'historique de chaque auditeur, et veut recommander des titres.

01 Identifiez au moins **4 des 5 V** , avec un exemple concret pour chacun.

02 En deux phrases, pourquoi **un seul serveur MySQL** ne suffirait-il pas ?

03 Quel principe permet de gérer ça ? Justifiez.

BARÈME : PARTIE A 5 PTS · PARTIE B 5 PTS