Prérequis & installation des outils pour les exercices pratiques

Module : Introduction au Big Data & Écosystème Hadoop
Enseignant : M. FALL**

> Ce document indique, **pour chaque exercice pratique du module**, l'outil requis et ses étapes d'installation.

1. Vue d'ensemble : quel exercice a besoin de quoi ?

Séance	Exercice	Outil requis	Installation
Cours 1	Exercice 1 (milieu) : 5 V	**Aucun** (raisonnement)	—
Cours 1	Exercice 2 (fin) : V/F + cas	**Aucun** (raisonnement)	—
Cours 2	Exercice 1 (milieu) : calcul de blocs	**Aucun** (calculatrice au besoin)	—
Cours 2	**TP guidé** : commandes HDFS	**Hadoop / HDFS**	§3 (obligatoire)
Cours 2	Exercice 2 (fin), partie commandes	**Hadoop / HDFS**	§3
Cours 3–4	MapReduce	**Hadoop** (déjà installé) + Java	§3 (rien à ajouter)
Cours 7	Hive	**Apache Hive** (sur Hadoop)	§6 (aperçu)
Cours 8	Spark	**Apache Spark** ou Databricks Community	§6 (aperçu)

À retenir : une seule installation lourde à faire, celle de Hadoop (§3). Elle sert pour les cours 2, 3 et 4. Hive et Spark viendront s'y ajouter plus tard.

2. Prérequis communs (avant toute installation Hadoop)

Ces éléments sont nécessaires quelle que soit la méthode choisie.

- **Système :** Linux (Ubuntu 22.04/24.04 conseillé). Sous **Windows**, passer par WSL2 (§4.A). Sous **macOS**, voir le guide dédié : `Prerequis_Installation_TP_BigData_macOS.pdf` (Homebrew, pas `apt`).
- **Java 11 (OpenJDK)** : requis par Hadoop 3.3.x.
- **SSH** : Hadoop démarre ses démons via SSH, même en local.
- **4 Go de RAM minimum** (8 Go confortable), **10 Go de disque libre**.

- Une connexion Internet pour le téléchargement (≈ 700 Mo pour Hadoop).

> **Conseil :** vérifie la version stable actuelle sur la page officielle des releases (https://hadoop.apache.orreleases.html) et adapte le numéro de version dans les commandes ci-dessous. Ce guide utilise **Hadoop 3.3.6** comme référence.

3. Installation de Hadoop (mode pseudo-distribué) : méthode native

Étape 1 : Installer Java 11

```
sudo apt update
sudo apt install openjdk-11-jdk -y
java -version        # doit afficher "openjdk version 11.x"
```

Étape 2 : Installer et configurer SSH (accès local sans mot de passe)

```
sudo apt install ssh -y
ssh-keygen -t rsa -P '' -f ~/.ssh/id_rsa
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
chmod 0600 ~/.ssh/authorized_keys
ssh localhost           # doit se connecter SANS demander de mot de passe
(taper "yes" la 1re fois)
exit
```

Étape 3 : Télécharger et installer Hadoop

```
cd ~
wget https://downloads.apache.org/hadoop/common/hadoop-3.3.6/hadoop-
3.3.6.tar.gz
# (si le lien échoue, versions archivées :
https://archive.apache.org/dist/hadoop/common/)
tar -xzf hadoop-3.3.6.tar.gz
sudo mv hadoop-3.3.6 /opt/hadoop
```

Étape 4 : Définir les variables d'environnement

Ajouter à la fin du fichier `~/.bashrc` :

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/opt/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
```

Puis appliquer :

```
source ~/.bashrc
```

Renseigner aussi `JAVA_HOME` dans le fichier de config Hadoop `$HADOOP_HOME/etc/hadoop/hadoop-env.sh` (dé-commenter la ligne et la remplir) :

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

Étape 5 : Configurer HDFS

Fichier `$HADOOP_HOME/etc/hadoop/core-site.xml` :

```
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://localhost:9000</value>
  </property>
</configuration>
```

Fichier `$HADOOP_HOME/etc/hadoop/hdfs-site.xml` :

```
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>
  <property>
    <name>dfs.namenode.name.dir</name>
    <value>/opt/hadoop/hdfs/namenode</value>
  </property>
  <property>
    <name>dfs.datanode.data.dir</name>
    <value>/opt/hadoop/hdfs/datanode</value>
  </property>
</configuration>
```

Créer les dossiers de stockage :

```
sudo mkdir -p /opt/hadoop/hdfs/namenode /opt/hadoop/hdfs/datanode
sudo chown -R $USER:$USER /opt/hadoop/hdfs
```

Étape 6 : Formater puis démarrer le cluster

```
hdfs namenode -format      # une seule fois, à la première installation
start-dfs.sh
```

```
jps                          # doit lister : NameNode, DataNode,
SecondaryNameNode
```

Étape 7 : Vérifier

- Interface web du NameNode : **http://localhost:9870**
- Test rapide en ligne de commande :

```
hdfs dfs -mkdir -p /user/etudiant
echo "bonjour big data" > test.txt
hdfs dfs -put test.txt /user/etudiant/
hdfs dfs -ls /user/etudiant
hdfs dfs -cat /user/etudiant/test.txt
```

Si le contenu s'affiche, **l'environnement est prêt pour le TP du cours 2.**

> **Note importante sur la réplication.** En pseudo-distribué (un seul DataNode), `dfs.replication` vaut **1**. C'est normal. Les exercices de calcul (facteur 3) restent **théoriques** : on raisonne comme sur un vrai cluster. Voir §4 pour la démo « panne de nœud ».

4. Méthodes alternatives d'installation

A. Sous Windows : via WSL2

1. Ouvrir PowerShell **en administrateur** :

```
wsl --install -d Ubuntu
```

2. Redémarrer, créer l'utilisateur Ubuntu, puis **suivre le §3** à l'intérieur d'Ubuntu (WSL).
3. L'interface web reste accessible depuis le navigateur Windows sur `http://localhost:9870`.

B. Via Docker (le plus rapide à distribuer, et nécessaire pour la démo multi-nœuds)

Docker évite toute installation manuelle : un même environnement pour tous.

1. Installer **Docker Desktop** (Windows/macOS) ou **Docker Engine** (Linux) : voir https://docs.docker.com/get-docker/.
2. Vérifier :

```
docker --version
```

3. Utiliser une image Hadoop prête à l'emploi ou un `docker-compose` multi-conteneurs (1 NameNode + plusieurs DataNodes) pour reproduire un vrai cluster avec réplication 3.

C. Bac à sable en ligne (zéro installation, pour la partie Spark surtout)

- **Databricks Community Edition** (gratuit) : environnement Spark complet dans le navigateur. Idéal pour le cours 8, ne demande qu'un compte et un navigateur.

5. Aperçu des ajouts pour les séances ultérieures

À installer **au-dessus** du Hadoop déjà en place, le moment venu :

- **Cours 3–4 (MapReduce)** : rien à ajouter. Les jobs tournent sur le Hadoop existant (Java déjà présent). Test : lancer l'exemple fourni `hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar pi 2 10`.
- **Cours 7 (Hive)** : télécharger Apache Hive, définir `HIVE_HOME`, initialiser le metastore (`schematool -dbType derby -initSchema`). Guide détaillé fourni avant la séance 7.
- **Cours 8 (Spark)** : soit Databricks Community (navigateur, recommandé pour débuter), soit Apache Spark local (`SPARK_HOME`, `pyspark`). Guide détaillé avant la séance 8.