TP Guidé HDFS

Objectif : manipuler HDFS en ligne de commande et observer la tolérance aux pannes.

Convention des équivalences

- **HDFS** : les commandes `hdfs dfs –…` et `hdfs fsck` sont **identiques** sur macOS, Linux et Windows (ce sont des outils Java).
- **Unix / macOS** : Terminal (`zsh` / `bash`).
- **Windows + WSL** : mêmes commandes qu'Unix (on est dans Ubuntu).
- **Windows natif** : PowerShell ou CMD, scripts Hadoop en `.cmd` (`start-dfs.cmd`).

Préalable : variables d'environnement

À lancer dans **chaque nouveau terminal** (ou à avoir dans `~/.zshrc`) :

```
export JAVA_HOME=/usr/local/opt/openjdk@11
export HADOOP_HOME=/opt/hadoop
export PATH="$JAVA_HOME/bin:$HADOOP_HOME/bin:$HADOOP_HOME/sbin:$PATH"
```

Windows (WSL)
`export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64`
`export HADOOP_HOME=/opt/hadoop`
idem Unix
`~/.bashrc`

Unix / macOS
`export JAVA_HOME=/usr/local/opt/openjdk@11`
`export HADOOP_HOME=/opt/hadoop`
`export PATH="$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin"`
Fichier permanent : `~/.zshrc`

Windows (PowerShell)
`$env:JAVA_HOME="C:\Program Files\Java\jdk-11"`
`$env:HADOOP_HOME="C:\hadoop"`
`$env:Path += ";$env:HADOOP_HOME\bin;$env:HADOOP_HOME\sbin"`
Variables d'environnement Windows, ou `$PROFILE`

Sous CMD (Windows natif) : `set JAVA_HOME=C:\Program Files\Java\jdk-11` puis `set PATH=%PATH%;%HADOOP_HOME%\bin;%HADOOP_HOME%\sbin`.

Étape 1 : Démarrer le cluster et vérifier les démons

```
start-dfs.sh
jps
```

Attendu dans `jps` :

- `NameNode`
- `DataNode`
- `SecondaryNameNode`

Interface web du NameNode : **http://localhost:9870**

Commande	Unix / macOS	Windows (WSL)	Windows (PowerShell / CMD)
Démarrer HDFS	`start-dfs.sh`	`start-dfs.sh`	`start-dfs.cmd`
Arrêter HDFS	`stop-dfs.sh`	`stop-dfs.sh`	`stop-dfs.cmd`
Lister les processus Java	`jps`	`jps`	`jps`

Étape 2 : Créer le répertoire de travail dans HDFS

```
hdfs dfs -mkdir -p /user/etudiant
hdfs dfs -ls /user
```

Attendu : le dossier `etudiant` apparaît.
`-p` crée les parents s'ils n'existent pas. Pas d'erreur = succès.

Commande HDFS	Unix / macOS	Windows (WSL)	Windows (PowerShell)
`hdfs dfs -mkdir -p /user/etudiant`	identique	identique	identique
`hdfs dfs -ls /user`	identique	identique	identique

Étape 3 : Créer un fichier local et le déposer dans HDFS

```
echo "bonjour HDFS - TP 2 Pour la L3IA ISM" > ~/mon_fichier.txt
```

```
hdfs dfs -put ~/mon_fichier.txt /user/etudiant/
```

Si le fichier existe déjà dans HDFS :

```
hdfs dfs -put -f ~/mon_fichier.txt /user/etudiant/
```

`-put` = copie **local → HDFS**.

Commande	Unix / macOS	Windows (WSL)	Windows (PowerShell)
Créer un fichier texte	`echo "…" > ~/mon_fichier.txt`	`echo "…" > ~/mon_fichier.txt`	`Set-Content -Path $HOME\mon_fichier.txt -Value "bonjour HDFS - TP cours 2"`
Dossier personnel	`~` ou `$HOME`	`~` ou `$HOME`	`$HOME` ou `%USERPROFILE%`
Déposer vers HDFS	`hdfs dfs -put ~/mon_fichier.txt /user/etudiant/`	identique	`hdfs dfs -put $HOME\mon_fichier.txt /user/etudiant/`
Écraser si déjà là	`hdfs dfs -put -f …`	identique	identique

Sous CMD : `echo bonjour HDFS - TP cours 2 > %USERPROFILE%\mon_fichier.txt`

Étape 4 : Vérifier : lister puis lire

```
hdfs dfs -ls /user/etudiant
hdfs dfs -cat /user/etudiant/mon_fichier.txt
```

Attendu : `bonjour HDFS - TP cours 2`

Commandes utiles du cours :

```
hdfs dfs -df -h                  # espace total / libre / utilisé
hdfs dfs -du -h /user/etudiant   # espace occupé par le dossier
```

Commande HDFS	Unix / macOS	Windows (WSL / PowerShell)	Équiv. Unix local
`hdfs dfs -ls /user/etudiant`	identique	identique	`ls /user/etudiant`
`hdfs dfs -cat /user/etudiant/mon_fichier.txt`	identique	identique	`cat /user/etudiant/mon_fi`
`hdfs dfs -df -h`	identique	identique	`df -h`

Commande HDFS	Unix / macOS	Windows (WSL / PowerShell)	Équiv. Unix local
`hdfs dfs -du -h /user/etudiant`	identique	identique	`du -h /user/etudiant`

Sous PowerShell, pour afficher un fichier **local** : `Get-Content` (équivalent de `cat`).

Étape 5 : Observer les blocs

```
hdfs fsck /user/etudiant/mon_fichier.txt -files -blocks -locations
```

À noter dans la sortie :

- le fichier est **HEALTHY**
- **1 bloc** (fichier tout petit, << 128 Mo)
- l'adresse du DataNode qui le porte
- éventuellement `Under-replicated` : normal si `dfs.replication = 1`

Commande HDFS	Unix / macOS	Windows (WSL / PowerShell)	Équiv. Unix local
`hdfs fsck … -files -blocks -locations`	identique	identique	Pas d'équivalent disque simple. Proche de `fsck` (contrôle d'intégrité) + « où sont les morceaux ».

Étape 6 : Tolérance aux pannes

Expérience A : 1 copie (setup actuel)

```
echo "fichier de test panne" > /tmp/panne.txt
hdfs dfs -put -f /tmp/panne.txt /user/etudiant/
hdfs dfs -cat /user/etudiant/panne.txt
```

Éteindre le DataNode, puis relire :

```
hdfs --daemon stop datanode
jps                                          # DataNode disparu
hdfs dfs -cat /user/etudiant/panne.txt       # → erreur
```

Attendu : erreur (DataNode down / blocs introuvables).
Le NameNode est encore là, mais **la seule copie** du bloc a disparu.

Relancer le DataNode :

```
hdfs --daemon start datanode
jps
hdfs dfs -cat /user/etudiant/panne.txt       # → le texte revient
```

Les blocs étaient encore sur le disque (`/opt/hadoop/hdfs/datanode`) ; le processus DataNode les a « rendus » de nouveau.

Commande	Unix / macOS	Windows (WSL)	Windows (PowerShell / CMD)
Fichier temporaire	`echo "…" > /tmp/panne.txt`	identique	`Set-Content $env:TEMP\panne.txt "fichier de test panne"`
Dépôt / lecture HDFS	`hdfs dfs -put` / `-cat`	identique	identique (`$env:TEMP\panne.txt` en source)
Arrêter le DataNode	`hdfs --daemon stop datanode`	identique	`hdfs --daemon stop datanode`
Relancer le DataNode	`hdfs --daemon start datanode`	identique	`hdfs --daemon start datanode`
Voir les démons	`jps`	`jps`	`jps`

Expérience B : 2 copies (fichier encore lisible)

Il faut **2 DataNodes** et **réplication 2**.

1. Dans `$HADOOP_HOME/etc/hadoop/hdfs-site.xml` , mettre :

```
<property>
  <name>dfs.replication</name>
  <value>2</value>
</property>
```

Chemin du fichier XML : Unix/macOS/WSL = `$HADOOP_HOME/etc/hadoop/hdfs-site.xml` ; Windows natif = `%HADOOP_HOME%\etc\hadoop\hdfs-site.xml` .

2. Créer le stockage du 2e DataNode, redémarrer, lancer le 2e processus :

```
mkdir -p /opt/hadoop/hdfs/datanode2
stop-dfs.sh
start-dfs.sh

hdfs --daemon start datanode \
  -Ddfs.datanode.data.dir=/opt/hadoop/hdfs/datanode2 \
```

```
  -Ddfs.datanode.address=0.0.0.0:9868 \
  -Ddfs.datanode.http.address=0.0.0.0:9865 \
  -Ddfs.datanode.ipc.address=0.0.0.0:9869

jps    # deux lignes DataNode
```

Vérifier http://localhost:9870 → **2 Live Nodes**.

3. Déposer / re-répliquer, puis éteindre **un seul** DataNode :

```
hdfs dfs -put -f /tmp/panne.txt /user/etudiant/
hdfs dfs -setrep -w 2 /user/etudiant/panne.txt
hdfs fsck /user/etudiant/panne.txt -files -blocks -locations

hdfs --daemon stop datanode
hdfs dfs -cat /user/etudiant/panne.txt    # → le fichier s'affiche encore
```

4. Remettre le 1er DataNode :

```
hdfs --daemon start datanode
```

Setup	Éteindre 1 DataNode	`-cat`
1 DataNode, réplication 1	seule copie perdue	**échoue**
2 DataNodes, réplication 2	une copie reste	**réussit**

Commande	Unix / macOS	Windows (WSL)	Windows (PowerShell / CMD)
Créer le dossier data	`mkdir -p /opt/hadoop/hdfs/datanode2`	identique	`New-Item -ItemType Directory -Force C:\hadoop\hdfs\datanode2`
Arrêter / démarrer HDFS	`stop-dfs.sh` / `start-dfs.sh`	identique	`stop-dfs.cmd` / `start-dfs.cmd`
2e DataNode	`hdfs --daemon start datanode -D…`	identique	identique (chemins Windows dans `-Ddfs.datanode.data.dir=…`
Forcer 2 réplicas	`hdfs dfs -setrep -w 2 /user/etudiant/panne.txt`	identique	identique

Étape 7 : Récupérer, nettoyer, arrêter (optionnel)

```
hdfs dfs -get /user/etudiant/mon_fichier.txt ~/recupere.txt
cat ~/recupere.txt
hdfs dfs -rm /user/etudiant/mon_fichier.txt
# plus tard :
# stop-dfs.sh
```

`-get` = copie **HDFS → local**.
`-rm` = supprimer un fichier dans HDFS.

Récap des commandes du TP

Commande	Rôle
`start-dfs.sh` / `stop-dfs.sh`	Démarrer / arrêter HDFS
`jps`	Voir NameNode, DataNode, SecondaryNameNode
`hdfs dfs -mkdir -p /user/etudiant`	Créer un répertoire
`hdfs dfs -put fichier.txt /user/etudiant/`	Local → HDFS
`hdfs dfs -ls /user/etudiant`	Lister
`hdfs dfs -cat /user/etudiant/fichier.txt`	Lire
`hdfs dfs -get ... .`	HDFS → local
`hdfs dfs -df -h`	Espace du cluster
`hdfs dfs -du -h /user/etudiant`	Espace d'un dossier
`hdfs dfs -rm ...`	Supprimer
`hdfs fsck ... -files -blocks -locations`	Voir les blocs et où ils sont
`hdfs --daemon stop/start datanode`	Éteindre / relancer un DataNode